

Восстановление графа пикселей MNIST

Протокол и результаты восстановления активной части решётки

Предмет проверки. По изображениям с одинаково перемешанными пикселями строится общий граф признаков. Оцениваются два свойства: совпадение с исходным соседством пикселей и качество классификации при подстановке найденного графа в уже обученную нейросеть. Ни координаты, ни метки цифр не используются при восстановлении.

В трёх сохранённых прогонах выбраны 487 активных пикселей и 1037 ± 8 рёбер. Геометрический F1 равен 0.759 ± 0.005 . При замене эталонного графа восстановленным среднее снижение ассигасы составляет 0.51 процентного пункта для GCN и 1.16 пункта для варианта GraphSAGE. Эксперимент показал успешное приближённое восстановление активной части решётки: найдено в среднем 80.5% её рёбер при precision 71.7%.

1 Как получен вход алгоритма

Использован датасет MNIST [3]: 60 000 обучающих и 10 000 тестовых изображений размера 28×28 с метками $0, \dots, 9$. Яркости делятся на 255, каждое изображение представляется строкой из 784 значений. Для одного запуска генерируется перестановка π , общая для всех изображений:

$$X_{s,j}^{\pi} = X_{s,\pi(j)}. \quad (1)$$

Индекс j — новая позиция, $\pi(j)$ — исходный пиксель. Рёбра в новых индексах переводятся для оценки в пары $(\pi(i), \pi(j))$. Известная оценщику решётка соединяет вертикальных и горизонтальных соседей; диагоналей и петель в эталоне нет. Она содержит

$$|E_{\text{grid}}| = 2 \cdot 28 \cdot 27 = 1512 \quad (2)$$

рёбер. В алгоритм эта матрица не передаётся.

2 Разбиение, параметры и выбор графа

Используются последовательные диапазоны исходного train-архива; предварительного случайного разбиения изображений нет. Границы ниже — индексы Python с исключённым правым концом.

Назначение	Строки train	Использование
Structure-train	[0, 10000)	Активность, корреляции, Lasso, Ridge
Structure-validation	[10000, 12000)	Энергия, отжиг, выбор штрафа
Classifier-train	[12000, 22000)	Обучение GNN по меткам
Classifier-validation	[22000, 24000)	Выбор checkpoint по cross-entropy
Official test	все 10 000	Итоговая классификация

Остальные 36 000 train-изображений в этих повторных прогонах не используются. Сохранены три seed перестановки: 20260904, 20260917, 20261003. Соответствующие seed восстановления — 42, 43, 44; обучения GNN — 100, 101, 102. Разбиения изображений одинаковы; между запусками меняются перестановка признаков и случайные состояния восстановления и обучения.

Восстановление использует $B = 4$, $K = 24$, Ridge $\alpha = 0.01$, 2000 шагов отжига и 12 предложений на шаг. Для каждого запуска независимо строятся три графа при $\lambda \in \{0.08, 0.10, 0.12\}$. Сравнивается непенилизированная сумма логарифмов проверочных ошибок:

$$L_{\lambda} = \mathcal{E}_{\lambda}(G_{\lambda}) - 2\lambda|E_{\lambda}|, \quad L_{*} = \min_{\lambda} L_{\lambda}. \quad (3)$$

Из графов с $L_{\lambda} \leq L_{*} + 0.01|L_{*}|$ выбирается самый разреженный. Во всех трёх опытах из проверенной сетки выбран штраф 0.08.

3 Сравнимые графы

Эталонная решётка. $A_{\text{ref},ij} = A_{\text{grid},\pi(i),\pi(j)}$. Известна оценщику и используется при обучении GNN. В старых JSON называется Oracle.

Восстановленный граф. Выход процедуры Lasso, Ridge-энергии, pruning и отжига. Размер графа определяется выбранной конфигурацией и данными.

Correlation top- E . Среди тех же активных вершин выбираются $|E_{\text{rec}}|$ пар с наибольшей *обычной абсолютной корреляцией Пирсона* на structure-train. Блочный score из алгоритма здесь не используется. Активное множество и бюджет рёбер передаются из результата восстановления.

Случайный граф. Равномерный выбор без возвращения $|E_{\text{rec}}|$ пар активных вершин. Совпадает число рёбер; распределение степеней не сохраняется. Имя Random degree-matched в старых GNN-метриках ошибочно; корректное название — edge-matched.

Неверно сопоставленная решётка. Выход остаётся X^π , но используется A_{grid} без согласованной перестановки. В ней 1512 рёбер.

4 Что именно делает классификатор

Использованы небольшие собственные реализации на PyTorch, основанные на идеях GCN и GraphSAGE [1, 2]. Применённые варианты архитектур заданы формулами ниже. Скрытая размерность — 12, выход — 10 классов; обучение выполняется с нуля. Для GCN используется нормировка

$$S = (D + I)^{-1/2}(A + I)(D + I)^{-1/2},$$

где D — диагональная матрица степеней A . Для одного изображения $h^{(0)} = x^\pi \in \mathbb{R}^{784 \times 1}$ код вычисляет

$$h^{(1)} = \text{ReLU}(h^{(0)}W_1 + \mathbf{1}b_1^\top), \quad (4)$$

$$h^{(2)} = \text{ReLU}(Sh^{(1)}W_2 + \mathbf{1}b_2^\top), \quad (5)$$

$$\ell = W_o \text{vec}(Sh^{(2)}) + b_o. \quad (6)$$

Для варианта SAGE определим $B = D_*^{-1/2}AD_*^{-1/2}$, $D_{*,ii} = \max(d_i, 1)$; петли не добавляются. Тогда

$$h^{(1)} = \text{ReLU}([h^{(0)} \| Bh^{(0)}]W_1 + \mathbf{1}b_1^\top), \quad (7)$$

$$h^{(2)} = \text{ReLU}([h^{(1)} \| Bh^{(1)}]W_2 + \mathbf{1}b_2^\top), \quad (8)$$

$$\ell = W_o \text{vec}(h^{(2)}) + b_o. \quad (9)$$

В варианте GraphSAGE применяется симметричная нормировка соседства. В обеих моделях признаки всех вершин объединяются операцией flatten. Последний линейный слой содержит отдельные веса для каждой позиции. Порядок вершин фиксирован для всех изображений.

Каждый классификатор обучается шесть эпох AdamW: learning rate 0.002 , weight decay 10^{-4} , batch size 512. Выбирается checkpoint с минимальной cross-entropy на classifier-validation. После этого для всех графов выполняется оценка с одними весами, без шагов оптимизатора. Весь классификационный запуск, включая обучение на согласованной решётке, уже ведётся в переставленной нумерации.

5 Визуальная проверка структуры




Рис. 1: Первый seed. Оранжевые вершины активны, синие исключены фильтром; рёбра красные. Исходные координаты используются только при построении рисунка. Граф восстановления взят из сохранённого NPZ одиночного прогона: его метрики совпадают с первым повтором. Корреляционный и случайный графы воспроизведены из сохранённого бюджета и seed; их структурные метрики проверены по JSON.

6 Совпадение с активной частью решётки

Сравнение проводится с $E_a = \{\{i, j\} \in E_{\text{grid}} : i, j \in V_a\}$. Во всех опытах $|V_a| = 487$, неактивных вершин 297, $|E_a| = 924$. Для предсказанного множества $\hat{E}$ определяются

$$TP = |\hat{E} \cap E_a|, \quad FP = |\hat{E} \setminus E_a|, \quad FN = |E_a \setminus \hat{E}|, \quad (10)$$

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2TP}{2TP + FP + FN}. \quad (11)$$

Число компонент в таблице относится к индуцированному графу на 487 активных вершинах. Изолированные 297 неактивных пикселей в него не включаются.

Таблица 1: Восстановленная структура по каждому seed.

Seed	$ E $	Precision	Recall	F_1	Компоненты	Макс. размер
20260904	1046	0.720	0.815	0.764	4	474
20260917	1035	0.717	0.803	0.758	3	482
20261003	1030	0.716	0.798	0.754	3	482

Таблица 2: Метрики структуры: среднее и выборочное SD.

Метод	Precision	Recall	F_1
Восстановленный	0.717 ± 0.002	0.805 ± 0.009	0.759 ± 0.005
Correlation top- E	0.753 ± 0.003	0.845 ± 0.003	0.796 ± 0.001
Случайный	0.009 ± 0.004	0.010 ± 0.005	0.010 ± 0.005

Среднее число рёбер 1037 на 12.2% больше 924 рёбер активной решётки. Восстановлено в среднем 80.5% эталонных связей; 71.7% найденных рёбер совпадают с эталоном. Во всех трёх запусках граф содержит 1030–1046 рёбер, а его крупнейшая компонента охватывает 474–482 из 487 активных вершин.

Correlation top- E точнее воспроизводит решётку при переданном бюджете. Его средний F_1 равен 0.796 при том же количестве рёбер, тогда как у полного алгоритма F_1 равен 0.759. Таким образом, найденный алгоритмом бюджет может использоваться и для корреляционного отбора связей.

7 Чувствительность к цене ребра

Таблица 3: Зависимость размера графа и проверочной ошибки от штрафа.

λ	Рёбра	L_{val}
0.08	1037.0 ± 8.2	-1071.70 ± 0.89
0.1	879.0 ± 9.5	-1039.67 ± 1.84
0.12	735.3 ± 2.5	-1004.21 ± 0.51

При повышении штрафа число рёбер уменьшается, а L_{val} растёт: качество линейного предсказания ухудшается. Параметр λ позволяет управлять компромиссом между разреженностью графа и ошибкой предсказания. Применённое правило выбора конфигурации сохранило вариант со средними 1037 рёбрами.

8 Результаты классификации с фиксированными весами

Accuracy — доля верных классов на 10 000 test-изображений:

$$\text{Acc} = \frac{1}{10000} \sum_s \mathbf{1}\{\arg \max_c \ell_{s,c} = y_s\}. \quad (12)$$

Таблица содержит среднее и выборочное SD по трём запускам. Парная разность в процентных пунктах вычислена внутри каждого запуска относительно его эталонного графа, затем усреднена.

Таблица 4: Test accuracy и парная разность к эталону (п.п.).

Модель	Граф	Accuracy	Δ к решётке
GCN	Решётка	0.894 ± 0.012	0.00 ± 0.00
GCN	Восстановленный	0.889 ± 0.011	-0.51 ± 0.09
GCN	Correlation top- E	0.892 ± 0.013	-0.23 ± 0.14
GCN	Случайный	0.447 ± 0.158	-44.73 ± 17.04
GCN	Неверная решётка	0.464 ± 0.062	-43.03 ± 7.18
GraphSAGE	Решётка	0.911 ± 0.002	0.00 ± 0.00
GraphSAGE	Восстановленный	0.900 ± 0.007	-1.16 ± 0.74
GraphSAGE	Correlation top- E	0.898 ± 0.011	-1.33 ± 0.99
GraphSAGE	Случайный	0.657 ± 0.139	-25.43 ± 14.13
GraphSAGE	Неверная решётка	0.726 ± 0.047	-18.50 ± 4.86

Дополнительно JSON сохраняет macro-F1 и NLL. Формулы и числа Ridge-energy к ним не относятся: Ridge используется для восстановления, cross-entropy — для обучения GNN.




Рис. 2: Ассигасу замороженных классификаторов. Полосы обозначают выборочное стандартное отклонение по трём запускам, а не доверительные интервалы.

9 Основные результаты

По матрице изображений с неизвестной алгоритму перестановкой пикселей успешно восстановлено приближённое соседство активной части решётки MNIST. Координаты, метки классов, исходный граф и его число рёбер для восстановления не использовались.

1. Выделены 487 активных вершин; почти постоянные пиксели оставлены изолированными.
2. В трёх запусках получены близкие по размеру разреженные графы: 1037 ± 8 рёбер, precision 0.717 ± 0.002 , recall 0.805 ± 0.009 , F1 0.759 ± 0.005 .
3. Размер восстановленного графа превышает размер активной решётки на 12.2%; основная часть активных вершин объединена в одну компоненту.
4. При подстановке найденного графа в замороженные классификаторы получены accuracy 0.889 ± 0.011 для GCN и 0.900 ± 0.007 для варианта GraphSAGE. Среднее снижение относительно эталонной решётки составило 0.51 и 1.16 процентного пункта.
5. Найденный бюджет рёбер также применён к корреляционному отбору, который получил геометрический F1 0.796 ± 0.001 .

Основной результат — восстановление большей части локального соседства пикселей из одних наблюдений при сохранении разреженной структуры. Повторные запуски дали близкие значения числа рёбер и качества восстановления.

10 Исходники и воспроизведение

Числа этого документа заново рассчитаны из исторического `repeated_metrics.json`; обучение ради переоформления отчёта не повторялось. Исторический `pilot_graph.npz` содержит граф и перестановку первого seed. Для остальных исторических seed сохранены метрики, но не списки рёбер и не веса GNN. Датасет и сырые артефакты не включены в Git-версию; для сборки PDF достаточно сохранённых LaTeX-таблиц и векторных рисунков. Для повторного запуска нужен внешний архив MNIST.

`original_sources/` содержит побайтовый снимок исходников проекта на дату подготовки пакета. В `src/` — отформатированная копия ядра и переносимый запуск:

```
python src/run_mnist.py --zip PATH_TO_MNIST.zip
```

Он записывает новые метрики и графы в `reruns/`, не меняя сохранённые данные отчёта. `--smoke` проверяет выполнение на малой выборке и не воспроизводит исследовательские числа. Текущий `recovery` дополнен обработкой неопределённых корреляций и диагностикой стадий; точная версия до этих дополнений в проекте не сохранена. Версии зависимостей и инструкции сборки LaTeX приведены в README пакета.

Список литературы

- [1] Kipf T. N., Welling M. Semi-Supervised Classification with Graph Convolutional Networks. ICLR, 2017. <https://arxiv.org/abs/1609.02907>.
- [2] Hamilton W. L., Ying R., Leskovec J. Inductive Representation Learning on Large Graphs. NeurIPS, 2017. <https://arxiv.org/abs/1706.02216>.
- [3] MNIST: описание датасета и официальных размеров разбиений. <https://www.tensorflow.org/datasets/catalog/mnist>.